

전공소개서

유민형

12ymh12@gmail.com

<https://gogoymh.github.io>

전공 요약

데이터가 부족한 상황에 적용 가능한
Semantic Segmentation

주 연구 분야

1. Neural Network for Semantic Segmentation

- Imaging modality, label Imbalance, data deficiency가 복합된 상황에서 semantic segmentation performance 향상을 위한 아키텍처 개발
- Real-time inferencing을 위한 효율적인 아키텍처 개발

2. Self/Semi-Supervised Learning

- 부족한 label로도 충분히 학습할 수 있는 Framework 개발

3. Federated Learning

- 개인 정보 보호 및 데이터 반출이 불가능한 상황을 위한 Framework 개발

연구 논문

- **Minhyeong Yu**, Sunwoo Kim, Seungjun Baek, “*Federated Semi-Supervised Segmentation with Randomized Weight Perturbation*”, (Under Review on MICCAI), 2022.
- Beom Suk Kim*, **Minhyeong Yu***, Sunwoo Kim, Joon Shik Yoon, Seungjun Baek, “*Scale-Attentional U-Net for the Segmentation of the Median Nerve in Ultrasound Images*”, (Accepted recently on Ultrasonography), 2021.

연구 논문 소개 - [1]

Federated Semi-Supervised Segmentation
with Randomized Weight Perturbation,
(Under Review on MICCAI), 2022

Introduction

“Federated Learning과 Semi-Supervised Segmentation을 결합한 framework”

- Medical Image Segmentation은 labeling cost가 가장 비싼 task 중 하나.
- 한 장소에 대규모의 데이터를 모으기도 어려움.
- Federated Learning과 Semi-Supervised Segmentation의 단순 결합은 학습이 잘 안되거나 communication cost를 많이 요구함.
- Federated Learning과 Semi-Supervised Segmentation을 결합한 연구가 거의 없고, 여러 조건과 현실적인 시나리오에서 실험하지 않음.

Introduction

3가지 기준에 부합하는 방법을 만들고자 함

- Model diversity
 - Generalization ability를 높이기 위해 여러 모델을 사용하기
- Model consistency
 - 여러 모델간 차이가 너무 크지 않게 하기
- Communication efficiency
 - 과도한 통신 비용이 발생하지 않도록 효율적으로 사용하기

Method

2.2 Randomized Weight Perturbation

We propose randomized weight perturbation (RWP) which randomly distorts the weights of the model. In contrast to previous approaches which applies random augmentation to training samples, RWP perturbs the model by multiplying random noise to the randomly selected weights of the neural network. Denote the weight tensor by W .

$$\tilde{W} = W \odot Z \quad (1)$$

where \tilde{W} denotes the perturbed weight tensor, and \odot denotes the elementwise multiplication. Z is a random tensor having the equal dimension as W . The i -th element of Z , denoted by Z_i , is defined as

$$Z_i = \begin{cases} G \sim \mathcal{N}(1, \sigma^2) & \text{w.p. } p, \\ 1 & \text{w.p. } 1 - p. \end{cases} \quad (2)$$

where $\mathcal{N}(\mu, \sigma^2)$ denotes the Gaussian distribution with mean μ and variance σ^2 . Thus Z randomly selects elements in W with probability (w.p.) p , and perturb the selected weights with i.i.d. Gaussian noise.

Weight에 random하게 perturbation을 곱해주는 방식을 제시

Method

적절한 random seed를 골라서 클라이언트에게 동일하게 보내줌

$$c_{i,j} := \frac{1}{|\mathcal{X}|} \sum_{x \in \mathcal{X}} \text{sim}\{f(x; \tilde{W}_i), f(x; \tilde{W}_j)\}, \quad i \neq j, \quad 1 \leq i, j \leq N$$

두 개의 perturbed network를 이용하여 서로의 pseudo label을 만듦

$$\mathcal{L}_{RWP}^k = \frac{1}{|\mathcal{U}^k|} \sum_{U \in \mathcal{U}^k} \left\{ \ell(f(U; \tilde{W}_1), Y_2) + \ell(f(U; \tilde{W}_2), Y_1) \right\}$$

Method

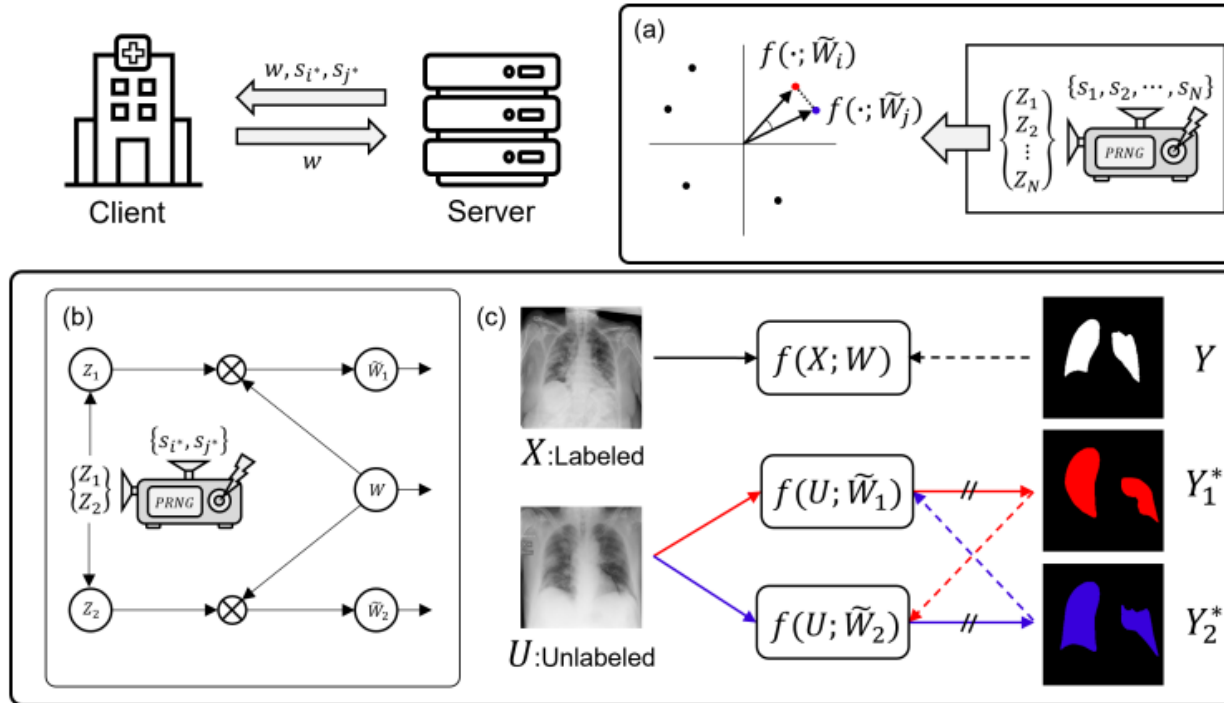
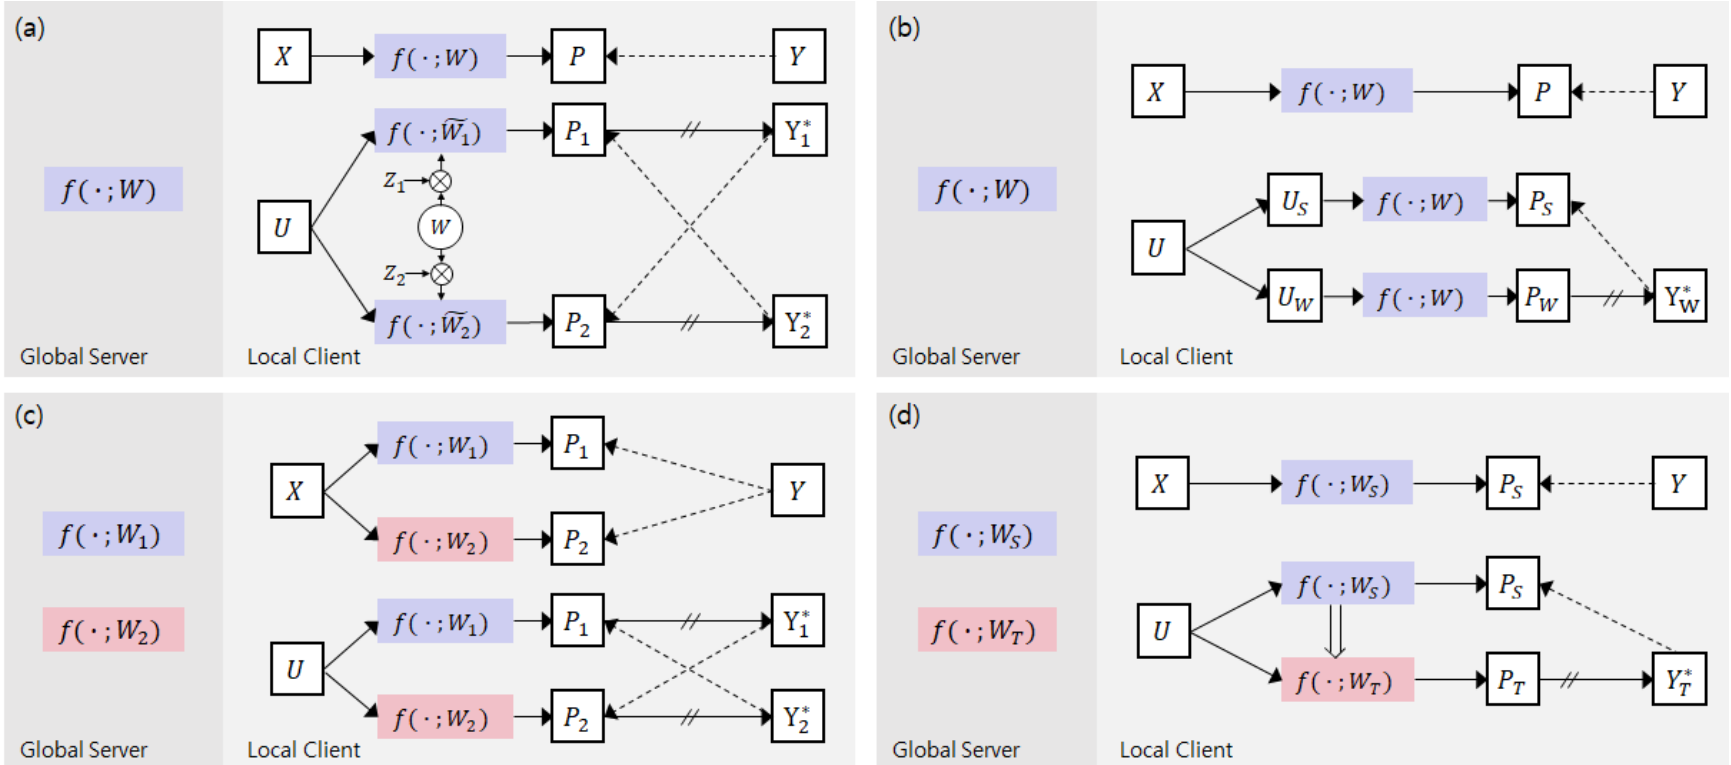


Fig. 1. Overview of FedWeP. Server transmits model parameters W and seed pair (s_{i^*}, s_{j^*}) . (a) Seed search based on cosine similarity at server side. (b) Randomized Weight Perturbation in forward pass. Two perturbed models \tilde{W}_1, \tilde{W}_2 and unperturbed model W are used at each client. In (a) and (b), both sites use the same Pseudo Random Number Generator (PRNG). (c) Semi-supervised segmentation using RWP at client side. ‘ \leftarrow ’ and ‘ ∇ ’ denote supervision and stop-gradient, respectively.

Random한 성질을 그냥 이용하지 않고,
Pseudo random number generator를 이용하여 조정함

Method



다른 3가지 semi-supervised segmentation framework 방식과 비교

(a) FedWeP (Ours), (b) PseudoSeg (PS)

(c) Cross Pseudo Supervision (CPS), (d) Mean Teacher (MT)

Result

Table 1. Label-at-Server Scenario

| Method | IID | | | | NonIID | | | | Cost |
|----------------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|---------------|
| | 1/16 | 1/8 | 1/4 | 1/2 | 1/16 | 1/8 | 1/4 | 1/2 | |
| MT (+ FedAvg) | 0.242 | 0.236 | 0.441 | 0.340 | 0.235 | 0.206 | 0.362 | 0.248 | 100% |
| CPS (+ FedAvg) | 0.693 | 0.711 | 0.739 | 0.765 | 0.677 | 0.702 | 0.730 | 0.736 | 100% |
| PS (+ FedAvg) | 0.200 | 0.293 | 0.426 | 0.441 | 0.293 | 0.349 | 0.367 | 0.456 | 50% |
| FedWeP-Random (Ours) | 0.557 | 0.593 | 0.662 | 0.694 | 0.598 | 0.631 | 0.699 | 0.703 | \approx 50% |
| FedWeP-Real (Ours) | 0.470 | 0.659 | 0.684 | 0.737 | 0.579 | 0.605 | 0.642 | 0.615 | \approx 50% |

Table 2. Label-at-Client Scenario

| Method | IID | | | | NonIID | | | | Cost |
|---------------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|---------------|
| | 1/16 | 1/8 | 1/4 | 1/2 | 1/16 | 1/8 | 1/4 | 1/2 | |
| FedAvg (Fully sup.) | 0.744 | | | | 0.742 | | | | 50% |
| MT (+ FedAvg) | 0.437 | 0.451 | 0.617 | 0.714 | 0.395 | 0.543 | 0.589 | 0.592 | 100% |
| CPS (+ FedAvg) | 0.583 | 0.700 | 0.720 | 0.727 | 0.599 | 0.586 | 0.674 | 0.728 | 100% |
| PS (+ FedAvg) | 0.601 | 0.661 | 0.675 | 0.693 | 0.542 | 0.567 | 0.631 | 0.640 | 50% |
| FedWeP (Ours) | 0.584 | 0.681 | 0.690 | 0.716 | 0.554 | 0.630 | 0.687 | 0.705 | \approx 50% |

여러 시나리오에 따른 실험을 진행하였고,
한 개의 모델을 전송하면서 두 개 모델 사용에 준하는 결과를 얻고자 함

Role

- 프레임워크 메인 아이디어 제시
- 코드 구현 및 실험 세팅
- 논문 작성 - 1저자


연구 논문 소개 - [2]

Scale-Attentional U-Net for the Segmentation
of the Median Nerve in Ultrasound Images
(Accepted recently on Ultrasonography), 2021

Introduction

“초음파 이미지에서 정중 신경 분할(Segmentation)에
특화된 신경망 아키텍처 개발”

- 고려대학교 구로병원 재활의학과 협력 연구
- 초음파 영상의 말초 신경 인식 및 지표 측정 자동화 목표

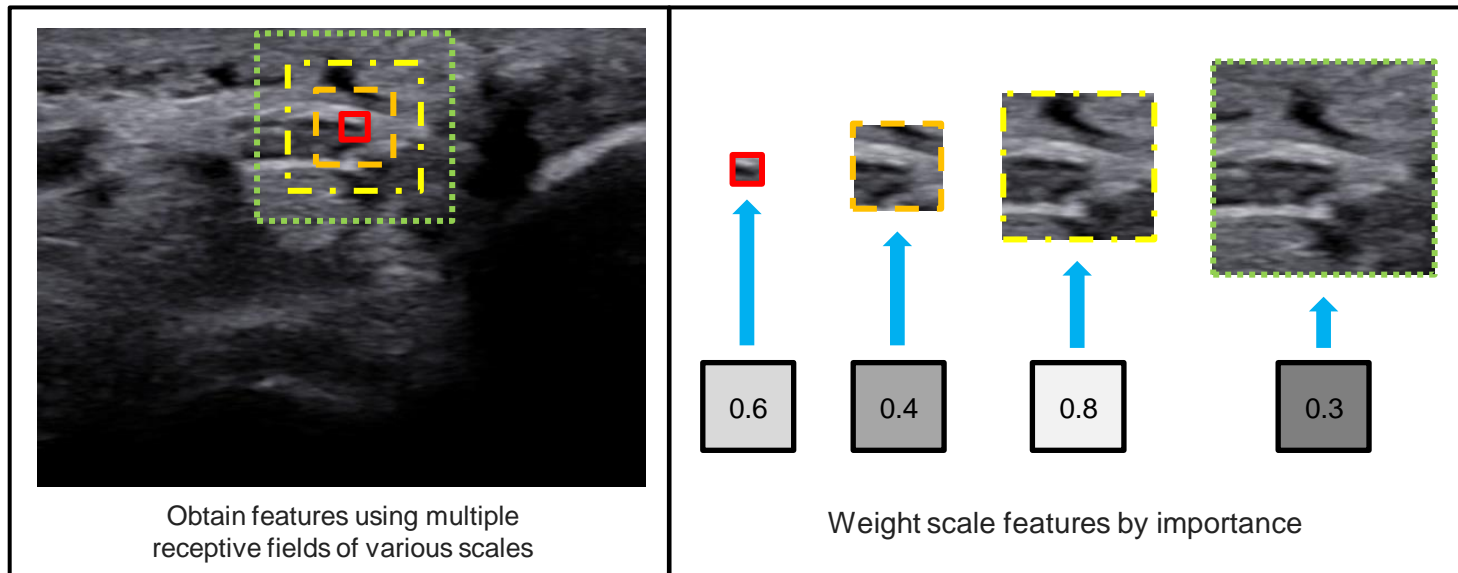


Requirement

- 의대 측 요구사항: 분할의 정확도가 최우선적
 - 단, 의학 저널에 투고하기 위해, 의사들도 이해할 만한 알고리즘을 선호
- 수집한 데이터: 손목과 팔꿈치의 정중 신경 초음파 이미지
 - 이미지 사이즈가 크고, 촬영 장비와 환자 상태에 따라 선명도가 다름
 - 정중 신경의 영역이 전체 크기의 1~2%로 라벨 불균형 심각
 - 대학 병원 교수 급 이상만 라벨링 가능한 극단적인 고비용
 - 전체적인 개수 부족, 데이터셋 별 최대 512장, 최소 153장
 - 흑백이라서 이미지 자체의 정보도 적은 경우에 해당
- 장기 프로젝트를 위한 첫 단계: 아키텍처 개발 필요
 - Supervised setup에서 실험하는데 데이터가 적어 과적합 우려
- 컴퓨터과학 측면의 novelty도 필요
 - Real-time으로 적용하기 위한 확장가능성 준비

Method

- 의사가 진단하는 방식에서 아이디어 착안
 - 임상가는 신경 주변의 해부학적 랜드마크를 참조하고, 신경이 벌집 모양의 성상일 것으로 예상하여 판단함
 - 그 방식을 모방하여, 정중 신경의 특징만 학습하지 않고, 주변의 랜드마크까지 참조하도록 구조적으로 설계



Method

- 컨볼루션과 어텐션을 적절히 조합하여,
feature뿐만 아니라 참조할 범위까지 학습

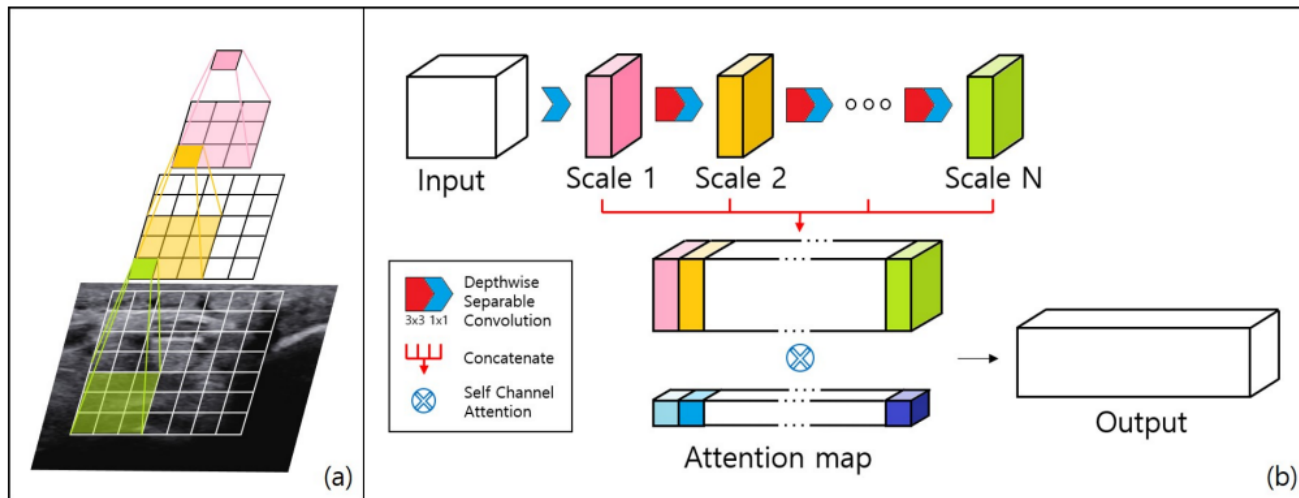


Figure 3.1: Architecture of Scale-attentional convolution (SCA-conv). (a) SCA-conv performs cascaded convolutions, without nonlinearity or pooling in-between, effectively using receptive fields of varying sizes. (b) Intermediate convolutional outputs form a concatenated feature map to which self-attention is applied in order to select and mix important scale features. In our implementations, the input is initially processed by 1×1 convolution and subsequently by 3×3 depthwise separable convolution (DSC). The total number of scales N can be either fixed(SCAUnet) or adaptively(SCAUnet-A) determined depending on the resolution of feature maps.

Quantitative Result

| Architecture | HM70A Wrist Dataset | | | |
|-------------------------|--------------------------|--------------------------|--------------------------|-------------------------|
| | Precision | Recall | Dice | HD |
| U-Net | 0.916 \pm 0.011 | 0.895 \pm 0.035 | 0.897 \pm 0.025 | 5.45 \pm 0.223 |
| U-Net++ | 0.913 \pm 0.009 | 0.884 \pm 0.018 | 0.889 \pm 0.011 | 5.58 \pm 0.103 |
| Attention U-Net | 0.918 \pm 0.008 | 0.890 \pm 0.015 | 0.896 \pm 0.010 | 5.44 \pm 0.088 |
| MultiRes U-Net | 0.934 \pm 0.007 | 0.869 \pm 0.020 | 0.893 \pm 0.014 | 5.47 \pm 0.101 |
| SCAUnet (ours) | 0.927 \pm 0.006 | 0.924 \pm 0.009 | 0.923 \pm 0.004 | 5.16 \pm 0.062 |
| SCAUnet-A (ours) | 0.922 \pm 0.010 | 0.929 \pm 0.010 | 0.923 \pm 0.004 | 5.18 \pm 0.074 |

| Architecture | HM70A Forearm Dataset | | | |
|-------------------------|--------------------------|--------------------------|--------------------------|-------------------------|
| | Precision | Recall | Dice | HD |
| U-Net | 0.763 \pm 0.070 | 0.738 \pm 0.040 | 0.719 \pm 0.042 | 5.44 \pm 0.441 |
| U-Net++ | 0.790 \pm 0.105 | 0.712 \pm 0.054 | 0.713 \pm 0.074 | 5.49 \pm 0.623 |
| Attention U-Net | 0.793 \pm 0.030 | 0.742 \pm 0.043 | 0.744 \pm 0.035 | 5.28 \pm 0.171 |
| MultiRes U-Net | 0.727 \pm 0.172 | 0.666 \pm 0.111 | 0.653 \pm 0.168 | 6.05 \pm 2.42 |
| SCAUnet (ours) | 0.793 \pm 0.028 | 0.759 \pm 0.036 | 0.761 \pm 0.030 | 5.21 \pm 0.151 |
| SCAUnet-A (ours) | 0.794 \pm 0.059 | 0.778 \pm 0.055 | 0.770 \pm 0.039 | 5.28 \pm 0.384 |

| Architecture | miniSONO Wrist Dataset | | | |
|-------------------------|--------------------------|--------------------------|--------------------------|-------------------------|
| | Precision | Recall | Dice | HD |
| U-Net | 0.859 \pm 0.043 | 0.829 \pm 0.027 | 0.830 \pm 0.027 | 5.43 \pm 0.382 |
| U-Net++ | 0.882 \pm 0.020 | 0.827 \pm 0.026 | 0.839 \pm 0.020 | 5.24 \pm 0.176 |
| Attention U-Net | 0.857 \pm 0.025 | 0.816 \pm 0.030 | 0.824 \pm 0.027 | 5.45 \pm 0.237 |
| MultiRes U-Net | 0.896 \pm 0.042 | 0.822 \pm 0.041 | 0.847 \pm 0.042 | 5.14 \pm 0.341 |
| SCAUnet (ours) | 0.903 \pm 0.014 | 0.898 \pm 0.016 | 0.897 \pm 0.012 | 4.97 \pm 0.173 |
| SCAUnet-A (ours) | 0.897 \pm 0.049 | 0.895 \pm 0.045 | 0.892 \pm 0.046 | 5.04 \pm 0.376 |


| Architecture | miniSONO Forearm Dataset | | | |
|-------------------------|--------------------------|--------------------------|--------------------------|-------------------------|
| | Precision | Recall | Dice | HD |
| U-Net | 0.873 \pm 0.037 | 0.828 \pm 0.027 | 0.838 \pm 0.024 | 4.67 \pm 0.282 |
| U-Net++ | 0.857 \pm 0.052 | 0.805 \pm 0.042 | 0.812 \pm 0.044 | 4.84 \pm 0.358 |
| Attention U-Net | 0.864 \pm 0.040 | 0.820 \pm 0.021 | 0.828 \pm 0.025 | 4.74 \pm 0.277 |
| MultiRes U-Net | 0.868 \pm 0.043 | 0.793 \pm 0.076 | 0.813 \pm 0.068 | 4.77 \pm 0.449 |
| SCAUnet (ours) | 0.878 \pm 0.013 | 0.850 \pm 0.017 | 0.858 \pm 0.010 | 4.53 \pm 0.133 |
| SCAUnet-A (ours) | 0.880 \pm 0.012 | 0.838 \pm 0.045 | 0.851 \pm 0.030 | 4.53 \pm 0.160 |

- Dice-coefficient 기준
4개의 데이터셋에서
최소 0.76에서 최대 0.92 달성
- Baseline인 Unet과 비교할 때
최소 1.68%에서 최대 4.95% 향상
- 전체 파라미터를 491K개만 사용,
연산량은 3.90 GFLOPS로
Unet보다 파라미터가 19.15배 적고
연산량은 17.03배 효율적
- Adaptive 버전은 164K개만 사용



| Architecture | Parameters | GFLOPS |
|-------------------------|----------------|-------------|
| U-Net | 9,421,569 | 66.42 |
| U-Net++ | 9,162,753 | 122.27 |
| Attention U-Net | 9,511,437 | 67.69 |
| MultiRes U-Net | 9,472,862 | 89.63 |
| SCAUnet (Ours) | 491,907 | 3.90 |
| SCAUnet-A (Ours) | 164,795 | 3.34 |

Qualitative Analysis



- 특이 사례만 소개 - 초록색: 의사가 라벨링한 GT, 빨간색: Prediction





(a) 두 덩이를 예측하길래 해당 환자를 다시 검사했더니, 실제로 신경이 두 갈래인 bifid median nerve인 것을 발견한 사례



(b) Prediction을 GT로 사용하여도 큰 문제가 없다고 생각되는 사례



(c) 정중 신경 epineurium이 아닌 내부 구성 요소 perineurium을 탐지한 사례
정중 신경의 패턴을 학습했다는 증거



(d, 왼) 신경과 붙어있는 혈관을 함께 탐지한 사례
신경이 타원 모양이라는 의학적 지식으로 커버 가능
(e, 오른) 완전 틀린 사례. 단, 전체 데이터셋의 0.82%

Accomplishment

- 본 연구 결과를 2020 대한신경근골격초음파학회 추계학술대회에 발표하여 우수구연상을 수상
- 연구 결과를 정리하여 의학 저널 Ultrasonography에 투고, 현재 리뷰 중(공동 1저자)
- 특허 출원
 - 발명의 명칭: “딥러닝 알고리즘 기반의 초음파 영상에서의 말초 신경 자동 인식 및 신경 지표 측정 방법 및 장치”, 10-2020-0067199, 2020.06.03.

Role

- 신경망 아키텍처 메인 아이디어 제시
- 이미지 전처리 및 마스크 추출
- 코드 구현 및 실험 세팅
- 논문 작성 - 공동 1저자
- 특허 작성

*다른 1저자는 의대 측 인원으로서,
데이터 수집과 정량적 분석을 담당.